


CNN基础与LeNet

1. MLP的局限性是什么？ 如何从MLP联系到CNN？

MLP运用：

	特征	
样本1	M_1	
样本2	M_2	

局限性：




参数太大！

减小输入维度

CNN替代MLP

2. 为什么CNN能够解决上述MLP的局限性？-----定性分析



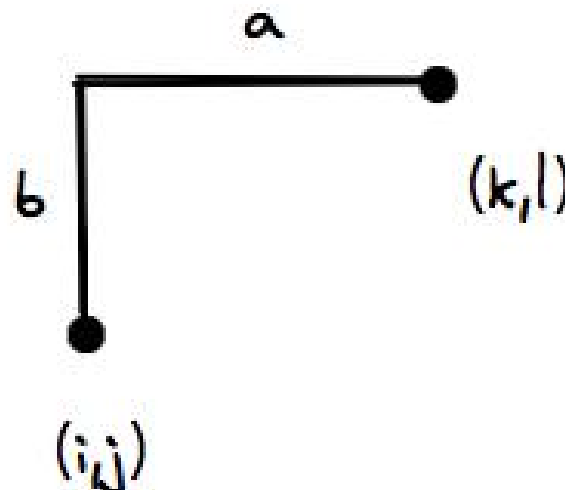
3. 为什么CNN能够解决上述MLP的局限性? -----量化分析

位置 (i, j) 处隐藏表示中的像素

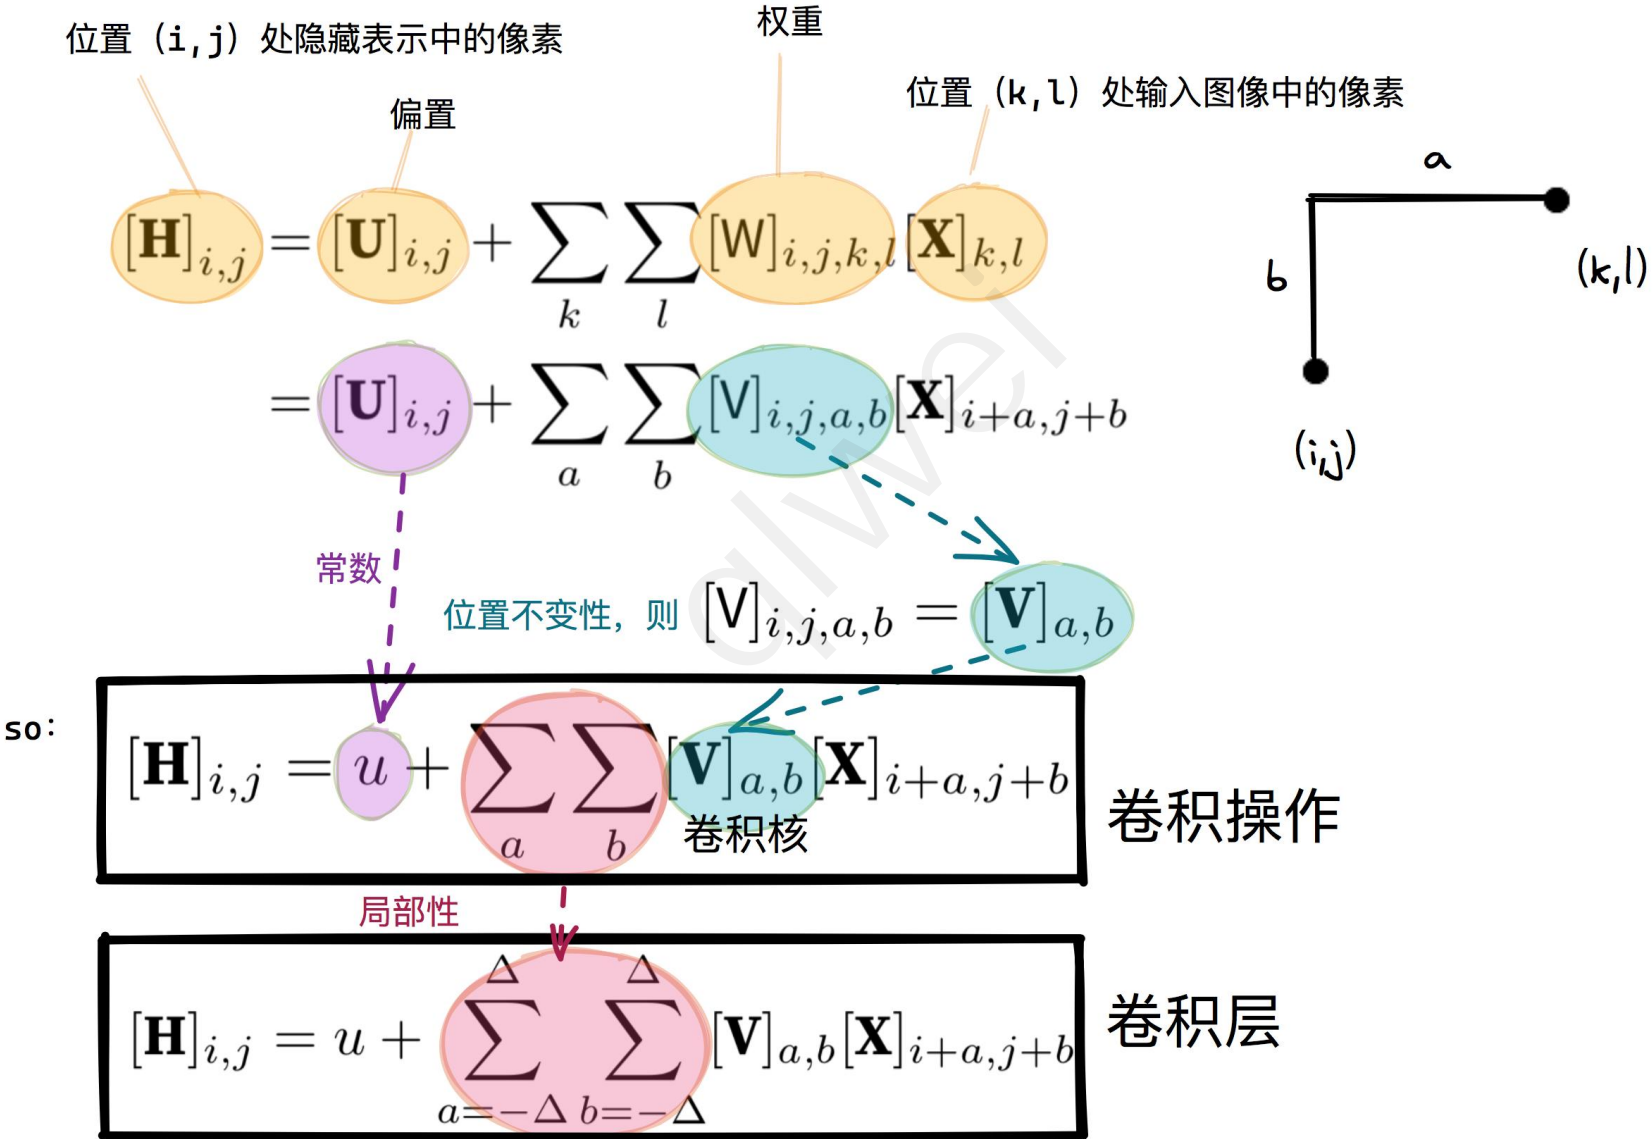
偏置

权重

位置 (k, l) 处输入图像中的像素

$$\begin{aligned} [\mathbf{H}]_{i,j} &= [\mathbf{U}]_{i,j} + \sum_k \sum_l [\mathbf{W}]_{i,j,k,l} [\mathbf{X}]_{k,l} \\ &= [\mathbf{U}]_{i,j} + \sum_a \sum_b [\mathbf{V}]_{i,j,a,b} [\mathbf{X}]_{i+a,j+b} \end{aligned}$$


3. 为什么CNN能够解决上述MLP的局限性？-----量化分析



回顾卷积公式

两个连续函数的卷积

$$(f * g)(\mathbf{x}) = \int f(\mathbf{z}) g(\mathbf{x} \text{ 翻转, 移位 } - \mathbf{z}) d\mathbf{z}$$

离散对象

$$(f * g)(i) = \sum_a f(a) g(i - a)$$

二维

$$(f * g)(i, j) = \sum_a \sum_b f(a, b) g(i - a, j - b)$$

理解


$$[\mathbf{H}]_{i,j} = u + \sum_a \sum_b [\mathbf{V}]_{a,b} [\mathbf{X}]_{i+a,j+b}$$

卷积操作

4. 二维张量？对于三通道图片怎么办？

$$[\mathbf{H}]_{i,j} = u + \sum_{a=-\Delta}^{\Delta} \sum_{b=-\Delta}^{\Delta} [\mathbf{V}]_{a,b} [\mathbf{X}]_{i+a,j+b}$$

卷积层



多个通道的卷积层

$$[\mathbf{H}]_{i,j,d} = \sum_{a=-\Delta}^{\Delta} \sum_{b=-\Delta}^{\Delta} \sum_c [\mathbf{V}]_{a,b,c,d} [\mathbf{X}]_{i+a,j+b,c}$$


隐藏层输出维度

以上，解析了“卷积层”的原理




简单实践

5. 图像中卷积应用




变小了。。。

6. 还有什么因素会影响输出的大小呢?



原图的边缘信息丢了 \longrightarrow 填充padding



分辨率冗余 \longrightarrow 步幅stride

padding

输入

0	0	0	0	0
0	0	1	2	0
0	3	4	5	0
0	6	7	8	0
0	0	0	0	0

核函数

0	1
2	3

*

=

输出

0	3	8	4
9	19	25	10
21	37	43	16
6	7	8	0

stride

输入

0	0	0	0	0
0	0	1	2	0
0	3	4	5	0
0	6	7	8	0
0	0	0	0	0

核函数

0	1
2	3

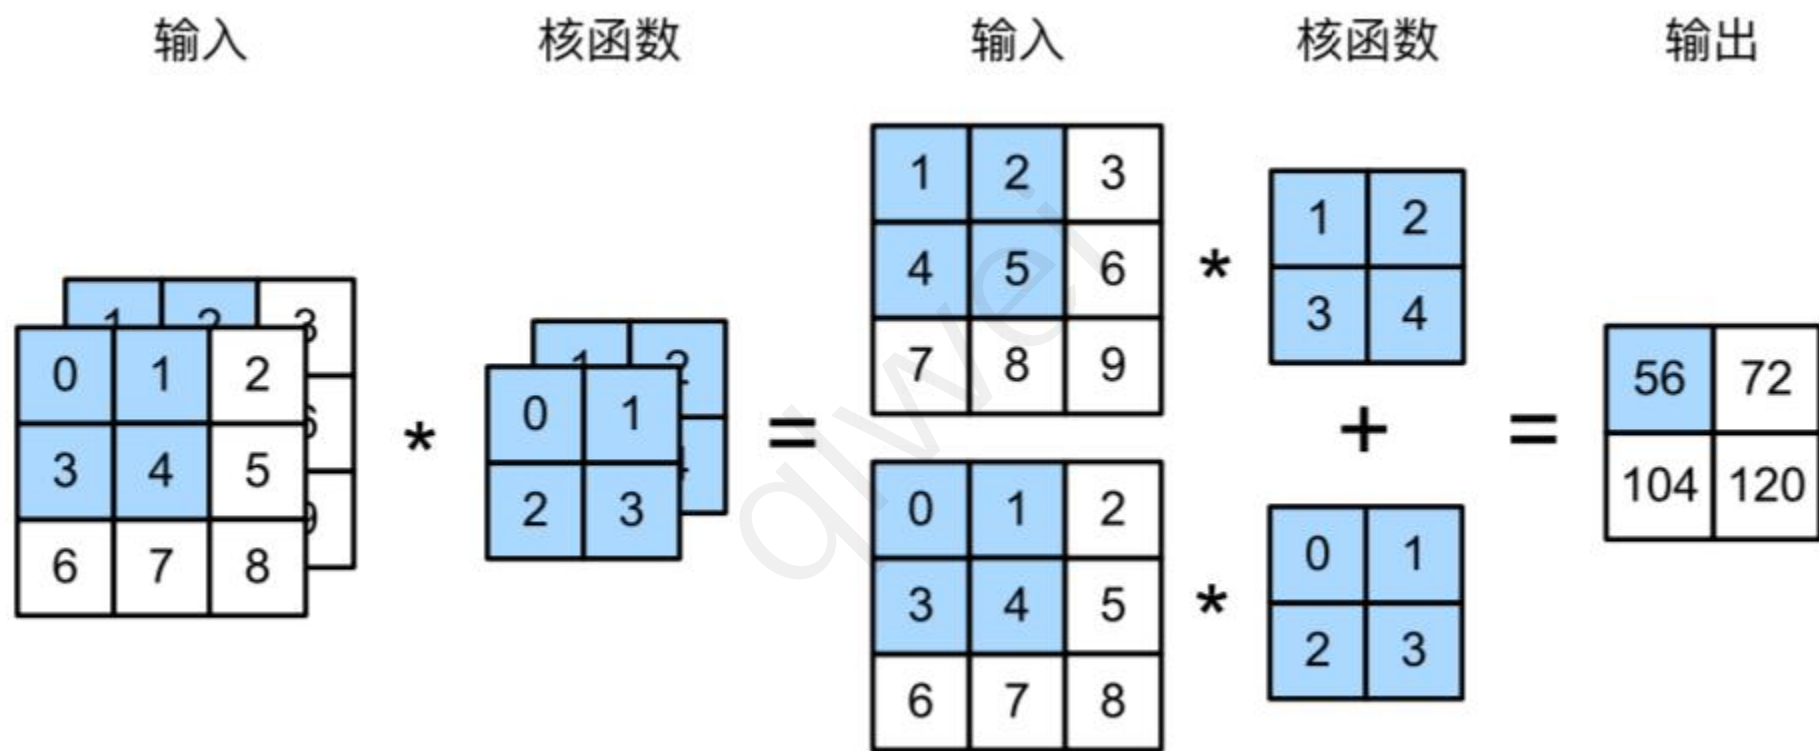
*

=

输出

0	8
6	8


7. 那么多通道的图像卷积运算？



8. 有没有1*1大小的卷积核？

输入输出相同宽高，通道数改变
(同一位置的线性组合)

调整通道数目，降低模型的复杂性



9. 多层卷积后如何表达全局抽象意义? ----pooling

输入

0	1	2
3	4	5
6	7	8

2 x 2 最大
汇聚层

选取最大值

输出

4	5
7	8

组件们over ~ ~ ~

迎来第一个CNN ~ ~ ~

LeNet

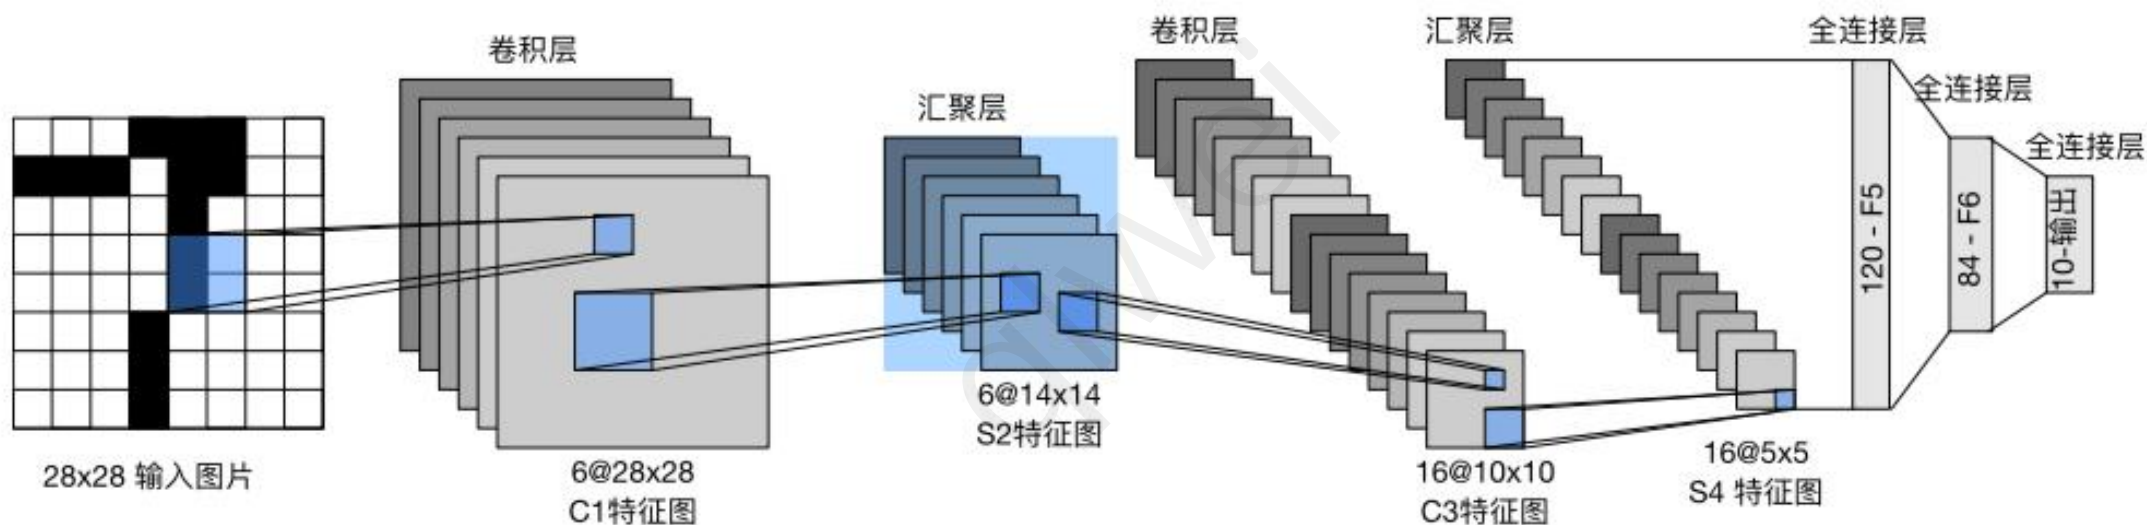


图6.6.1: LeNet中的数据流。输入是手写数字，输出为10种可能结果的概率。

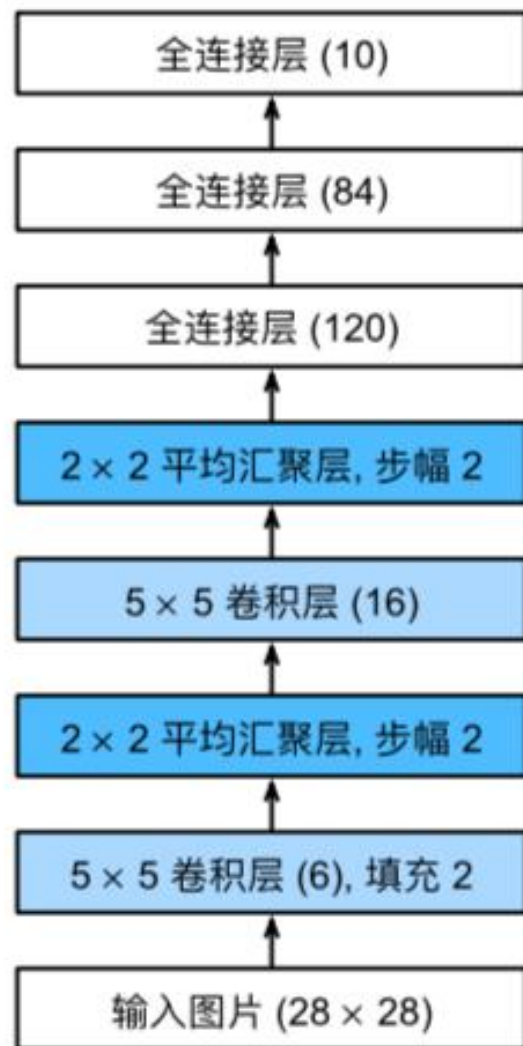


图6.6.2: LeNet 的简化版。

层与块？




图5.1.1: 多个层被组合成块，形成更大的模型

